

Clasificación Automática de Variedades de Frijoles Secos mediante Técnicas de Machine Learning

Joseph Roldán*, Duban Zuluaga[†], Juan Esteban Cardozo Rivera[‡]

Departamento de Ingeniería de Sistemas, Universidad de Antioquia, Medellín, Colombia

Modelos y Simulación II — Prof. Julián D. Arias-Londoño

Correos: {joseph.rolدان, duban.zuluaga1, juan.cardozo}@udea.edu.co

Resumen—Este trabajo aborda el problema de la clasificación automática de siete variedades de frijol seco (Dermason, Sira, Seker, Horoz, Cali, Barbunya y Bombay) a partir de 16 características geométricas extraídas mediante un sistema de visión por computador. Se emplea el *Dry Bean Dataset* del repositorio UCI, compuesto por 13.611 muestras. Se presenta un análisis exploratorio detallado del conjunto de datos, se identifica la configuración del problema como clasificación supervisada multiclase y se revisan cinco trabajos previos que han abordado el mismo problema. En etapas posteriores del proyecto se evaluarán al menos cinco modelos de aprendizaje de máquina y técnicas de reducción de dimensión.

I. INTRODUCCIÓN

El frijol seco es una de las leguminosas comestibles de mayor producción a nivel mundial, con una amplia diversidad genética que se refleja en múltiples variedades con características morfológicas similares entre sí [1]. La calidad de la semilla es un factor determinante en la producción agrícola, y garantizar la uniformidad de las variedades es esencial tanto para el mercado como para la producción sostenible. Sin embargo, la clasificación manual de semillas resulta lenta, costosa e inconsistente cuando se manejan grandes volúmenes de producción.

En este contexto, los sistemas de visión por computador combinados con técnicas de aprendizaje de máquina (ML) ofrecen una alternativa objetiva y automatizada para la clasificación de semillas. Koklu y Ozkan [1] desarrollaron un sistema que captura imágenes de granos de frijol con una cámara de alta resolución y extrae características geométricas (dimensiones y formas) que alimentan modelos de clasificación multiclase.

El presente trabajo utiliza el *Dry Bean Dataset* [1] para diseñar, entrenar y evaluar un sistema de predicción basado en ML. En esta primera entrega se presenta la descripción del problema, el análisis exploratorio de los datos y una revisión del estado del arte.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto y utilidad de aplicar Machine Learning

En la agroindustria, la clasificación de granos es esencial para asegurar la calidad del producto y cumplir con las exigencias del mercado. Actualmente, este proceso suele ser manual o depende de sistemas automáticos basados en reglas sencillas, como límites fijos de tamaño, color o forma. El problema es que estos métodos son lentos, dependen excesivamente de la experiencia del operador y pierden precisión cuando las

variedades son muy similares o presentan variaciones naturales debido al cultivo o al almacenamiento.

En este proyecto nos enfocamos en la clasificación automática de siete tipos de frijoles secos (Barbunya, Bombay, Cali, Dermason, Horoz, Seker y Sira) analizando 16 características morfométricas extraídas de imágenes digitales (como área, perímetro, compacidad y excentricidad). Para ello, utilizamos un conjunto de 13.611 muestras, lo que proporciona una base sólida para entrenar y comparar diversos algoritmos.

Implementar ML es ventajoso porque, en lugar de basarse en reglas manuales definidas por un programador, los modelos aprenden directamente de los datos, identificando qué rasgos diferencian mejor cada variedad. Esto permite gestionar la variabilidad natural de los granos sin ajustes constantes. Además, la capacidad de clasificar una muestra en milisegundos hace que el sistema sea viable para líneas de producción o controles de calidad en tiempo real, resultando en un proceso más rápido, objetivo y escalable que reduce la dependencia de la inspección visual humana.

II-B. Descripción de la base de datos

El *Dry Bean Dataset* [1] fue recolectado por Koklu y Ozkan (2020) y se encuentra disponible en el repositorio UCI Machine Learning. Está compuesto por 13.611 muestras correspondientes a granos de 7 variedades de frijol seco, fotografiados con una cámara de alta resolución. Mediante etapas de segmentación y extracción de características sobre las imágenes, se obtuvieron 16 variables predictoras: 12 de dimensión y 4 de forma. La Tabla I describe cada variable.

Todas las variables predictoras son numéricas: *Area* y *ConvexArea* son enteras, mientras que las restantes 14 son reales de punto flotante. La variable objetivo (*Class*) es categórica nominal con 7 niveles sin orden inherente. No se requiere codificación adicional de las variables predictoras, pero la variable objetivo debe codificarse numéricamente para los modelos de ML (por ejemplo, mediante *Label Encoding*).

Datos faltantes y duplicados. El dataset no contiene valores faltantes en ninguna variable, por lo que no fue necesaria ninguna estrategia de imputación. Se identificaron 68 registros duplicados (0,5 % del total), los cuales se eliminarán antes del entrenamiento para evitar sesgo por sobreexposición de muestras idénticas.

Distribución de clases. La distribución de las clases presenta un desbalance moderado, como se observa en la Tabla II. La

Cuadro I
DESCRIPCIÓN DE LAS VARIABLES DEL DATASET.

#	Variable	Descripción
1	Area	Número de píxeles dentro del contorno
2	Perimeter	Longitud del borde del grano
3	MajorAxisLength	Longitud del eje mayor
4	MinorAxisLength	Longitud del eje menor
5	AspectRatio	Razón eje mayor / eje menor
6	Eccentricity	Excentricidad de la elipse equivalente
7	ConvexArea	Píxeles del polígono convexo mínimo
8	EquivDiameter	Diámetro del círculo de igual área
9	Extent	Razón área / <i>bounding box</i>
10	Solidity	Razón píxeles casco convexo / grano
11	Roundness	$(4\pi A)/P^2$
12	Compactness	$EquivDiameter / MajorAxisLength$
13–16	ShapeFactor 1–4	Factores de forma adicionales

clase mayoritaria es Dermason con 3.546 muestras (26,0 %) y la minoritaria es Bombay con 522 muestras (3,8 %), lo que representa una razón de desbalance de 6,8:1. Este desbalance debe considerarse tanto en la selección de métricas de evaluación como en el posible uso de técnicas de submuestreo o sobremuestreo durante el entrenamiento.

Cuadro II
DISTRIBUCIÓN DE CLASES EN EL DATASET.

Clase	Muestras	Proporción (%)
DERMASON	3.546	26,0
SIRA	2.636	19,4
SEKER	2.027	14,9
HOROZ	1.928	14,2
CALI	1.630	12,0
BARBUNYA	1.322	9,7
BOMBAY	522	3,8
Total	13.611	100,0

Análisis de correlación. Se identificaron 21 pares de variables con correlación de Pearson $|r| > 0,9$, lo cual evidencia alta multicolinealidad. Las variables de tamaño (*Area*, *ConvexArea*, *Perimeter*, *EquivDiameter*, *MajorAxisLength*, *MinorAxisLength*) están altamente correlacionadas entre sí, al igual que las variables de forma (*Compactness*, *ShapeFactor3*, *AspectRatio*, *Eccentricity*). Destaca el par *Area–ConvexArea* con $r = 0,9999$. Esta redundancia justifica la aplicación de técnicas de reducción de dimensión como PCA y UMAP en etapas posteriores del proyecto.

Poder discriminativo. El análisis de histogramas y box-plots por clase reveló que: (i) la variedad Bombay se separa claramente del resto por su mayor tamaño en todas las variables dimensionales; (ii) las variables de forma (*Compactness*, *Eccentricity*, *Roundness*) permiten distinguir entre variedades como Seker (más redondeada) y Horoz (más alargada); (iii) las variedades Sira y Dermason presentan el mayor solapamiento

entre todas las combinaciones de variables analizadas, constituyendo el par más difícil de clasificar; y (iv) las variables *Extent*, *Solidity* y *ShapeFactor4* exhiben bajo poder discriminativo, con distribuciones muy similares entre clases.

II-C. Paradigma de aprendizaje

El problema se configura como una tarea de **clasificación supervisada multiclase**. Es supervisada porque se dispone de etiquetas conocidas para cada muestra (la variedad de frijol fue identificada previamente por expertos). Es multiclase porque la variable objetivo tiene 7 categorías nominales mutuamente excluyentes.

Esta configuración es la apropiada dado que: (i) el objetivo es asignar una categoría discreta (no un valor continuo), descartando la regresión; (ii) las clases son mutuamente excluyentes, ya que un grano pertenece a exactamente una variedad; y (iii) se cuenta con suficientes muestras etiquetadas (13.611) para entrenar y validar modelos supervisados con técnicas como la validación cruzada estratificada.

Dado el desbalance moderado de clases, se emplearán métricas como el F1-score macro (que pondera igualmente el desempeño en cada clase) y el F1-score weighted (que pondera por la frecuencia de cada clase), además del accuracy global. Se reportarán matrices de confusión para identificar los pares de clases con mayor tasa de error.

III. ESTADO DEL ARTE

A continuación se describen cinco trabajos que han abordado la clasificación de variedades de frijol seco utilizando el mismo dataset empleado en este proyecto.

Koklu y Ozkan (2020) [1] publicaron el artículo original que introduce el dataset. Emplearon un paradigma de clasificación supervisada multiclase con cuatro modelos: *Multilayer Perceptron* (MLP), *Support Vector Machine* (SVM), *k-Nearest Neighbors* (kNN) y *Decision Tree* (DT). La validación se realizó con *10-fold cross-validation*. Las métricas reportadas fueron el accuracy por clase y el accuracy global. Los resultados mostraron accuracies globales de 91,73 %, 93,13 %, 87,92 % y 92,52 % para MLP, SVM, kNN y DT respectivamente, siendo SVM el mejor modelo con un 93,13 %.

Khan et al. (2023) [2] compararon ocho clasificadores (Logistic Regression, Naïve Bayes, kNN, Decision Tree, Random Forest, XGBoost, SVM y MLP) con clases balanceadas e imbalanceadas. Para el preprocesamiento, emplearon el método IQR para eliminación de *outliers* y el algoritmo ADASYN para sobremuestreo sintético. Usaron *10-fold cross-validation* con métricas de accuracy, sensibilidad, especificidad y coeficiente kappa de Cohen. El clasificador XGBoost obtuvo el mejor rendimiento con 93,0 % en clases imbalanceadas y 95,4 % con clases balanceadas mediante ADASYN.

Krishnan (2023) [3] desarrolló un modelo multiclase utilizando 22 algoritmos de ML sobre un dataset balanceado mediante submuestreo aleatorio (522 muestras por clase). Además, aplicó la transformación Box-Cox para reducir la asimetría de las variables. La validación se realizó con *10-fold cross-validation*, reportando accuracy, precisión, recall y

F1-score. El algoritmo CatBoost alcanzó la mayor accuracy media de 93,8 % (rango: 92,05 % a 95,35 %).

Li et al. (2024) [4] propusieron un enfoque combinado de sobremuestreo con BLSMOTE (*Borderline-SMOTE*), agrupamiento con K-means, y clasificación con SVM, DT y RF. El objetivo fue abordar simultáneamente el desbalance de clases y la dificultad de clasificación en las fronteras entre clases. Usaron validación cruzada con métricas de accuracy, precisión, recall, F1-score y AUC-ROC. El método BLSMOTE + K-means + SVM superó a los métodos tradicionales en las métricas evaluadas.

Mukherjee et al. (2025) [5] propusieron un enfoque de aprendizaje supervisado centrado en el manejo del desbalance de datos. Implementaron una técnica de remuestreo híbrido SMOTE-ENN, que combina el sobremuestreo sintético con la limpieza de fronteras mediante vecinos editados. El núcleo del sistema se basó en un clasificador *Light Gradient Boosting Machine* (LGBM), optimizado mediante optimización bayesiana, e integró una selección de características por correlación y el uso de análisis SHAP para garantizar la interpretabilidad del modelo. La validación se llevó a cabo mediante una validación cruzada estratificada de 12 pliegues para el ajuste de hiperparámetros, mientras que la evaluación final se realizó sobre una división 80/20. El desempeño fue medido a través de precisión, recall, F1-score, matriz de confusión y curva ROC-AUC. Los resultados destacan un accuracy del 99,59 % y un F1-score de 0,9957, superando a SVM y KNN (99,57 %). El análisis SHAP permitió identificar que el perímetro y la compacidad son las características geométricas con mayor influencia en las predicciones.

La Tabla III resume los principales resultados del estado del arte.

Cuadro III
RESUMEN DEL ESTADO DEL ARTE.

Referencia	Mejor modelo	Valid.	Métri- ca	Result.
Koklu (2020)	SVM	10-fold CV	Acc.	93,13 %
Khan (2023)	XGBoost + ADASYN	10-fold CV	Acc.	95,40 %
Krishnan (2023)	CatBoost	10-fold CV	Acc.	93,80 %
Li (2024)	BLSMOTE + K-means + SVM	CV	Multi	Sup.*
Mukherjee (2025)	LGBM + SMOTE-ENN	12-fold CV	Acc.	99,59 %

*Reportan superioridad en accuracy, F1 y AUC frente a métodos base.

REFERENCIAS

[1] M. Koklu e I. A. Ozkan, “Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques,” *Computers and Electronics in Agriculture*, vol. 174, art. 105507, 2020. DOI: 10.1016/j.compag.2020.105507.

[2] M. S. Khan, T. D. Nath, M. M. Hossain *et al.*, “Comparison of multiclass classification techniques using dry bean dataset,” *International Journal of Cognitive Computing in Engineering*, vol. 4, pp. 6–20, 2023. DOI: 10.1016/j.ijcce.2023.01.002.

[3] S. Krishnan, “Identification of Dry Bean Varieties Based on Multiple Attributes Using CatBoost Machine Learning Algorithm,” *Scientific Programming*, art. 2556066, 2023. DOI: 10.1155/2023/2556066.

[4] C. Li *et al.*, “Clustering and classification for dry bean feature imbalanced data,” *Scientific Reports*, vol. 14, art. 82253, 2024. DOI: 10.1038/s41598-024-82253-6.

[5] A. Mukherjee, M. R. Chalak Qazani, B. M. J. Rana *et al.*, “SMOTE-ENN resampling technique with Bayesian optimization for multi-class classification of dry bean varieties,” *Applied Soft Computing*, vol. 181, art. 113467, 2025. DOI: 10.1016/j.asoc.2025.113467.