

Clasificación Automática de Variedades de Frijoles Secos mediante Técnicas de Machine Learning

Joseph Roldán*, Duban Zuluaga[†], Carlos Zuluaga[‡]

Departamento de Ingeniería de Sistemas, Universidad de Antioquia, Medellín, Colombia

Modelos y Simulación II — Prof. Julián D. Arias-Londoño

Correos: {joseph.rolan, duban.zuluaga1, andres.zuluaga6}@udea.edu.co

Resumen—Este trabajo aborda la clasificación automática de siete variedades de frijol seco (Dermason, Sira, Seker, Horoz, Cali, Barbunya y Bombay) a partir de 16 características geométricas extraídas por visión por computador. Se entrenan y comparan siete modelos de aprendizaje supervisado (Regresión Logística, kNN, SVM, MLP, Random Forest, XGBoost y LightGBM) combinados con tres estrategias de manejo del desbalance de clases (sin balanceo, SMOTE y SMOTE-ENN), totalizando 21 configuraciones experimentales. Se evalúa además la reducción de dimensión mediante PCA y UMAP sobre los dos mejores modelos. El mejor desempeño fue obtenido por SVM sin balanceo, con un F1-macro de 0,9358 y accuracy del 92,54 % sobre el conjunto de prueba, resultado alineado con el trabajo seminal de Koklu y Ozkan (2020). PCA con 7 componentes permite reducir la dimensión un 56 % manteniendo prácticamente el mismo desempeño.

I. INTRODUCCIÓN

El frijol seco es una de las leguminosas comestibles de mayor producción a nivel mundial, con una amplia diversidad genética que se refleja en múltiples variedades con características morfológicas similares entre sí [1]. La calidad de la semilla es un factor determinante en la producción agrícola, y garantizar la uniformidad de las variedades es esencial tanto para el mercado como para la producción sostenible. La clasificación manual de semillas resulta lenta, costosa e inconsistente cuando se manejan grandes volúmenes de producción.

Los sistemas de visión por computador combinados con técnicas de aprendizaje de máquina (ML) ofrecen una alternativa objetiva y automatizada. Koklu y Ozkan [1] desarrollaron un sistema que captura imágenes de granos con una cámara de alta resolución y extrae 16 características geométricas que alimentan modelos de clasificación multiclase.

El presente trabajo utiliza el *Dry Bean Dataset* [1] para diseñar, entrenar y evaluar un sistema de predicción basado en ML. Se compararon siete modelos y tres estrategias de balanceo, además de técnicas lineales y no lineales de reducción de dimensión.

II. DESCRIPCIÓN DEL PROBLEMA

II-A. Contexto y utilidad de aplicar Machine Learning

En la agroindustria, la clasificación de granos es esencial para asegurar la calidad del producto y cumplir con las exigencias del mercado. Actualmente este proceso suele ser manual o depende de sistemas automáticos basados en reglas

sencillas (límites fijos de tamaño, color o forma). Estos métodos son lentos, dependen excesivamente de la experiencia del operador y pierden precisión cuando las variedades son muy similares o presentan variaciones naturales debido al cultivo o al almacenamiento.

En este proyecto se aborda la clasificación automática de siete tipos de frijoles secos (Barbunya, Bombay, Cali, Dermason, Horoz, Seker y Sira) analizando 16 características morfométricas extraídas de imágenes digitales. Implementar ML es ventajoso porque, en lugar de basarse en reglas manuales definidas por un programador, los modelos aprenden directamente de los datos. Esto permite gestionar la variabilidad natural de los granos sin ajustes constantes, y la capacidad de clasificar en milisegundos hace viable el uso del sistema en líneas de producción o controles de calidad en tiempo real.

II-B. Descripción de la base de datos

El *Dry Bean Dataset* [1] fue recolectado por Koklu y Ozkan (2020) y se encuentra en el repositorio UCI Machine Learning. Está compuesto por 13.611 muestras de 7 variedades de frijol seco, fotografiados con una cámara de alta resolución. Mediante segmentación y extracción de características, se obtuvieron 16 variables predictoras: 12 de dimensión y 4 de forma. La Tabla I describe cada variable.

Cuadro I
DESCRIPCIÓN DE LAS VARIABLES DEL DATASET.

#	Variable	Descripción
1	Area	Número de píxeles dentro del contorno
2	Perimeter	Longitud del borde del grano
3	MajorAxisLength	Longitud del eje mayor
4	MinorAxisLength	Longitud del eje menor
5	AspectRatio	Razón eje mayor / eje menor
6	Eccentricity	Excentricidad de la elipse equivalente
7	ConvexArea	Píxeles del polígono convexo mínimo
8	EquivDiameter	Diámetro del círculo de igual área
9	Extent	Razón área / <i>bounding box</i>
10	Solidity	Razón píxeles casco convexo / grano
11	Roundness	$(4\pi A)/P^2$
12	Compactness	$EquivDiameter / MajorAxisLength$
13–16	ShapeFactor 1–4	Factores de forma adicionales

Todas las variables predictoras son numéricas: *Area* y *ConvexArea* son enteras, mientras que las restantes 14 son reales de punto flotante. La variable objetivo (*Class*) es categórica nominal con 7 niveles sin orden inherente. La variable objetivo se codifica numéricamente para los modelos de ML mediante *Label Encoding*.

Datos faltantes y duplicados. El dataset no contiene valores faltantes. Se identificaron 68 registros duplicados (0,5 % del total), eliminados antes del entrenamiento.

Distribución de clases. Las clases presentan un desbalance significativo (Tabla II): la mayoritaria es Dermason con 3.546 muestras (26,0 %) y la minoritaria es Bombay con 522 (3,8 %), una razón de 6,8:1. Este desbalance debe considerarse en la selección de métricas y en el posible uso de técnicas de sobremuestreo, abordadas en la sección siguiente.

Cuadro II
DISTRIBUCIÓN DE CLASES EN EL DATASET.

Clase	Muestras	Proporción (%)
DERMASON	3.546	26,0
SIRA	2.636	19,4
SEKER	2.027	14,9
HOROZ	1.928	14,2
CALI	1.630	12,0
BARBUNYA	1.322	9,7
BOMBAY	522	3,8
Total	13.611	100,0




Figura 1. Distribución de las 7 clases en el dataset (izquierda) y proporciones (derecha). Se evidencia el desbalance entre DERMASON y BOMBAY.

Análisis de correlación. Se identificaron 21 pares de variables con correlación de Pearson $|r| > 0,9$, lo cual evidencia alta multicolinealidad. Las variables de tamaño (*Area*, *ConvexArea*, *Perimeter*, *EquivDiameter*, *MajorAxisLength*) están altamente correlacionadas entre sí, al igual que las variables de forma (*Compactness*, *ShapeFactor3*, *AspectRatio*, *Eccentricity*). Destaca el par *Area-ConvexArea* con $r = 0,9999$. Esta redundancia justifica la aplicación de técnicas de reducción de dimensión, analizadas en la Sección V.




Figura 2. Matriz de correlación de Pearson entre las 16 variables predictoras. La alta multicolinealidad se observa en bloques de variables de tamaño y de forma.

Poder discriminativo. El análisis por clase de histogramas (Fig. 3) y boxplots (Fig. 4) reveló cuatro hallazgos: (i) Bombay se separa claramente del resto por su mayor tamaño en todas las variables dimensionales; (ii) las variables de forma permiten distinguir entre Seker (más redondeada) y Horoz (más alargada); (iii) Sira y Dermason presentan el mayor solapamiento, constituyendo el par más difícil de clasificar; y (iv) *Extent*, *Solidity* y *ShapeFactor4* exhiben bajo poder discriminativo (confirmado en la Sección V con información mutua).




Figura 3. Histogramas normalizados por clase para las 16 variables. Las variables de tamaño separan a Bombay; las de forma diferencian Seker, Horoz y Cali.




Figura 4. Boxplots por clase de 8 variables clave (4 de tamaño y 4 de forma).

II-C. Paradigma de aprendizaje

El problema se configura como **clasificación supervisada multiclase**: supervisada porque se dispone de etiquetas conocidas para cada muestra, y multiclase porque la variable objetivo tiene 7 categorías mutuamente excluyentes. Las clases nominales descartan la regresión, y el tamaño del dataset (13.611) permite entrenar y validar modelos supervisados con validación cruzada estratificada.

Dado el desbalance de clases, se emplean métricas como F1-score macro (que pondera igualmente cada clase), F1-score weighted (que pondera por frecuencia) y accuracy global. Se reportan matrices de confusión para identificar los pares de clases con mayor tasa de error.

III. ESTADO DEL ARTE

A continuación se describen cinco trabajos que han abordado la clasificación de variedades de frijol seco utilizando el mismo dataset.

Koklu y Ozkan (2020) [1] publicaron el artículo original. Emplearon clasificación supervisada multiclase con cuatro modelos: MLP, SVM, kNN y árbol de decisión. La validación se realizó con *10-fold cross-validation* y se reportó accuracy por clase y global. SVM fue el mejor con un 93,13 % de accuracy.

Khan et al. (2023) [2] compararon ocho clasificadores con clases balanceadas e imbalanceadas. Para el preprocesamiento, eliminaron *outliers* con el método IQR y aplicaron el algoritmo **ADASYN** (*Adaptive Synthetic Sampling*), una variante de SMOTE que genera más muestras sintéticas para las clases minoritarias en regiones donde la densidad de la clase mayoritaria es alta, focalizando el sobremuestreo en las zonas más difíciles de clasificar. Usaron *10-fold cross-validation* y XGBoost obtuvo 93,0 % sin balanceo y 95,4 % con ADASYN.

Krishnan (2023) [3] desarrolló un modelo multiclase con 22 algoritmos sobre un dataset balanceado por submuestreo aleatorio (522 muestras por clase). Aplicó la transformación **Box-Cox**, una transformación no lineal de la forma $y = (x^\lambda - 1)/\lambda$ que aproxima las distribuciones a una normal, reduciendo la asimetría de las variables y mejorando el desempeño de modelos sensibles a la forma de la distribución. CatBoost alcanzó 93,8 % de accuracy.

Li et al. (2024) [4] propusieron un enfoque combinado con **BLSMOTE** (*Borderline-SMOTE*), una variante de SMOTE que genera muestras sintéticas únicamente a partir de las muestras minoritarias situadas en la frontera entre clases (es decir, aquellas cuya mayoría de vecinos pertenecen a otras clases), donde la clasificación es más difícil. Esto evita generar muestras en zonas ya bien clasificadas. Combinaron BLSMOTE con K-means y SVM/DT/RF, superando a métodos tradicionales.

Mukherjee et al. (2025) [5] propusieron un enfoque centrado en el manejo del desbalance mediante **SMOTE-ENN**, una técnica híbrida que primero aplica SMOTE para generar muestras sintéticas de las clases minoritarias y luego aplica *Edited Nearest Neighbors* (ENN) para eliminar las muestras (originales o sintéticas) cuya clase difiere de la mayoría de sus vecinos. El resultado es un dataset balanceado con fronteras más limpias entre clases. El sistema usó un clasificador LightGBM optimizado mediante optimización bayesiana, validación cruzada estratificada de 12 pliegues y análisis SHAP para interpretabilidad. Alcanzaron 99,59 % de accuracy.

La Tabla III resume los principales resultados del estado del arte.

Cuadro III
RESUMEN DEL ESTADO DEL ARTE.

Referencia	Mejor modelo	Valid.	Métrica	Result.
Koklu (2020)	SVM	10-fold CV	Acc.	93,13 %
Khan (2023)	XGBoost + ADASYN	10-fold CV	Acc.	95,40 %
Krishnan (2023)	CatBoost	10-fold CV	Acc.	93,80 %
Li (2024)	BLSMOTE + K-means + SVM	CV	Multi	Sup.*
Mukherjee (2025)	LGBM + SMOTE-ENN	12-fold CV	Acc.	99,59 %

*Reportan superioridad en accuracy, F1 y AUC frente a métodos base.

IV. ENTRENAMIENTO Y EVALUACIÓN DE MODELOS

IV-A. Configuración experimental

Preprocesamiento. Se eliminaron los 68 duplicados y se aplicó *Label Encoding* a la variable objetivo. Las variables predictoras se estandarizaron con *StandardScaler* (media cero, desviación uno), ajustado sólo sobre el conjunto de entrenamiento para evitar fuga de información.

Validación. Se realizó una partición estratificada 80/20 (10.834 muestras para entrenamiento, 2.709 para prueba). Sobre el conjunto de entrenamiento se aplicó búsqueda aleatoria de hiperparámetros con validación cruzada estratificada de 5 pliegues, optimizando el F1-score macro como métrica primaria (apropiada para clases desbalanceadas).

Modelos evaluados. La Tabla IV resume los modelos y rangos de hiperparámetros explorados. Se incluyen los cinco tipos solicitados por la guía: paramétrico (Regresión Logística), no paramétrico (kNN), ensamble de árboles (Random Forest), red neuronal (MLP) y SVM. Adicionalmente se incluyen XGBoost

y LightGBM, dos ensambles por *boosting* (donde cada árbol corrige los errores acumulados de los anteriores, a diferencia de RF que entrena árboles en paralelo); se incluyen para evaluar si las técnicas más recientes superan a los modelos clásicos en este dataset.

Cuadro IV
MODELOS E HIPERPARÁMETROS EXPLORADOS.

Modelo	Hiperparámetros
LogReg	$C \in \{0, 1; 1; 10\}$
kNN	$n_neighbors \in \{3, 5, 7, 9\}$, $weights \in \{uniform, distance\}$
SVM	$C \in \{1, 10\}$, $\gamma \in \{scale, 0, 1\}$, $kernel = RBF$
MLP	$hidden \in \{(50,), (100,)\}$, $alpha \in \{0, 001; 0, 01\}$
RandomForest	$n_estimators=150$, $max_depth \in \{None, 20\}$
XGBoost	$n_estimators \in \{100, 200\}$, $max_depth \in \{3, 6\}$, $lr \in \{0, 1; 0, 2\}$
LightGBM	$n_estimators \in \{100, 200\}$, $max_depth \in \{-1, 20\}$, $lr \in \{0, 05; 0, 1\}$

Estrategias de balanceo. Para abordar el desbalance se compararon tres estrategias aplicadas exclusivamente al conjunto de entrenamiento dentro del pipeline de validación cruzada: (i) sin balanceo (baseline), (ii) **SMOTE** (*Synthetic Minority Oversampling Technique*), que genera muestras sintéticas interpolando entre vecinos cercanos de la misma clase, y (iii) **SMOTE-ENN**, la combinación híbrida descrita en la Sección anterior. Esto da un total de $7 \times 3 = 21$ configuraciones experimentales.

Métricas. Se reportan accuracy, F1-macro, F1-weighted, precisión y recall macro sobre el conjunto de prueba. La media y desviación estándar del F1-macro en validación cruzada se utilizan como estimación del intervalo de confianza.

IV-B. Resultados del entrenamiento

La Fig. 5 y el mapa de calor de la Fig. 6 resumen el desempeño de las 21 configuraciones. La Tabla V muestra las cinco mejores combinaciones por F1-macro.




Figura 5. F1-macro en test para las 21 configuraciones (7 modelos $\times$ 3 estrategias de balanceo). SVM y MLP destacan sobre el resto.




Figura 6. Heatmaps de accuracy (izquierda) y F1-macro (derecha) por modelo y estrategia de balanceo.

Cuadro V
TOP 5 CONFIGURACIONES POR F1-MACRO EN TEST.

#	Modelo	Balanceo	Acc.	F1-m	F1-w
1	SVM	None	0,9254	0,9358	0,9254
2	SVM	SMOTE	0,9243	0,9353	0,9244
3	MLP	SMOTE	0,9228	0,9336	0,9230
4	MLP	None	0,9225	0,9331	0,9226
5	LightGBM	SMOTE	0,9206	0,9318	0,9208

El mejor modelo es **SVM sin balanceo** con F1-macro = 0,9358 (CV: $0,934 \pm 0,004$). Tres hallazgos principales:

- **El balanceo no aporta mejora sustancial.** El desbalance 6,8:1, si bien significativo, no fue lo suficientemente severo como para que SMOTE o SMOTE-ENN aportaran. SMOTE-ENN *empeoró* el desempeño en la mayoría de modelos, probablemente porque elimina muestras útiles en la frontera SIRA/DERMASON ya de por sí difícil.
- **Modelos clásicos son competitivos.** SVM y MLP superan a los modelos de *boosting* más recientes en este dataset cuando no se emplea ingeniería de *features* ni optimización extensiva de hiperparámetros.
- **Reproducción del SOTA.** Nuestro F1-macro de 0,9358 con SVM coincide con el accuracy de 93,13 % reportado por Koklu y Ozkan [1], validando la implementación.

La Fig. 7 muestra la matriz de confusión del mejor modelo. BOMBAY se clasifica perfectamente (precisión y recall = 1,00). SIRA es la clase con menor desempeño (F1 = 0,879), confundiéndose principalmente con DERMASON, en línea con lo esperado del EDA.




Figura 7. Matriz de confusión (conteos y porcentajes) del mejor modelo (SVM sin balanceo) sobre el conjunto de prueba.

Cuadro VI
REPORTE POR CLASE DEL MEJOR MODELO (SVM SIN BALANCEO).

Clase	Precision	Recall	F1	Support
BARBUNYA	0,9269	0,9094	0,9181	265
BOMBAY	1,0000	1,0000	1,0000	104
CALI	0,9194	0,9448	0,9319	326
DERMASON	0,9164	0,9281	0,9222	709
HOROZ	0,9667	0,9355	0,9508	372
SEKER	0,9439	0,9532	0,9485	406
SIRA	0,8831	0,8748	0,8789	527
Macro avg	0,9366	0,9351	0,9358	2.709

V. REDUCCIÓN DE DIMENSIÓN

V-A. Análisis individual de variables

Se calculó la **información mutua** entre cada variable y la clase, junto con el **módulo de la correlación de Spearman**. La información mutua mide la cantidad de información que una variable aporta sobre la clase (incluyendo relaciones no lineales), mientras que Spearman mide la monotonía. La Fig. 8 muestra los resultados.




Figura 8. Información mutua (izquierda) y $|\rho|$ de Spearman (derecha) de cada variable con la clase. *Extent*, *Solidity* y *ShapeFactor4* son las menos discriminativas.

Las variables *Extent* (MI = 0,20), *Solidity* (MI = 0,23) y *ShapeFactor4* (MI = 0,36) son las que menos información aportan, confirmando lo observado en el EDA donde sus distribuciones se solapaban entre clases. Las más informativas son *Perimeter*, *ConvexArea*, *Area*, *EquivDiameter* y *MajorAxisLength* (todas con MI $\geq 0,99$). Dado el alto número de variables correlacionadas, en lugar de descartar manualmente se aplican técnicas sistemáticas de reducción.

V-B. PCA — Reducción lineal

PCA se aplicó sobre los datos estandarizados. La Fig. 9 muestra la varianza explicada por cada componente. Se eligieron dos criterios para seleccionar el número de componentes: capturar al menos el 95 % y el 99 % de la varianza, lo que resulta en 4 y 7 componentes respectivamente.




Figura 9. Varianza explicada por componente (izquierda) y acumulada (derecha). Cuatro componentes capturan el 95 % y siete capturan el 99,6 %.




Figura 10. Proyección PCA 2D del conjunto de entrenamiento. BOMBAY se separa fácilmente; SIRA y DERMASON se solapan.

Se reevaluaron los dos mejores modelos (SVM y MLP) con los hiperparámetros óptimos previos, esta vez usando los componentes principales como entrada (Tabla VII).

Cuadro VII
RESULTADOS DE PCA SOBRE LOS DOS MEJORES MODELOS.

Modelo	Config.	Var. (%)	Red. (%)	Acc.	F1-m
SVM	4 PCs	95,04	75,0	0,8915	0,8940
MLP	4 PCs	95,04	75,0	0,8889	0,8911
SVM	7 PCs	99,61	56,2	0,9247	0,9350
MLP	7 PCs	99,61	56,2	0,9251	0,9348

Con 7 componentes (reducción del 56 % en dimensión) el desempeño se mantiene prácticamente idéntico al modelo original. Con 4 componentes el desempeño cae aproximadamente 4 puntos, indicando que el 5 % restante de varianza es informativo para la clasificación.

V-C. UMAP — Reducción no lineal

UMAP es una técnica de reducción de dimensión no lineal basada en la preservación de la estructura topológica de los datos: busca un espacio de baja dimensión donde los puntos cercanos en el espacio original permanezcan cercanos. Se usaron los hiperparámetros por defecto ($n_neighbors=15$, $min_dist=0,1$). Para una comparación justa con PCA, se evaluaron 5 y 7 componentes.




Figura 11. Proyección UMAP 2D del conjunto de entrenamiento. La separación visual es más clara que en PCA 2D, pero la separabilidad lineal en más dimensiones es similar.

Cuadro VIII
RESULTADOS DE UMAP SOBRE LOS DOS MEJORES MODELOS.

Modelo	Comp.	Red. (%)	Acc.	F1-m
SVM	5	68,8	0,9118	0,9245
MLP	5	68,8	0,9062	0,9200
SVM	7	56,2	0,9073	0,9206
MLP	7	56,2	0,9066	0,9194

V-D. Discusión y conclusiones

La Fig. 12 resume la comparación entre features originales, PCA y UMAP.




Figura 12. Comparación de F1-macro: features originales vs PCA vs UMAP.

Hallazgos principales:

- 1. PCA con 7 componentes es la mejor opción de reducción,** manteniendo el desempeño y reduciendo la dimensión un 56 %. Esto se explica por la alta multicolinealidad detectada en el EDA: una vez eliminada la redundancia lineal, la información esencial cabe en pocos componentes.
- 2. UMAP no superó a PCA.** A pesar de mostrar una mejor separación visual en 2D, en 5 y 7 componentes UMAP es inferior a PCA. Esto sugiere que la estructura del

dataset es predominantemente lineal en su dimensión informativa, y los métodos no lineales aportan menos.

- 3. La reducción a 4 componentes pierde información.** El 5 % de varianza adicional entre 4 y 7 componentes es relevante para la clasificación.

Comparación con el estado del arte. La Tabla IX compara nuestro mejor resultado con los trabajos revisados.

Cuadro IX
COMPARACIÓN CON EL ESTADO DEL ARTE.

Trabajo	Configuración	Acc.
Koklu (2020)	SVM	93,13 %
Khan (2023)	XGBoost + ADASYN	95,40 %
Krishnan (2023)	CatBoost + Box-Cox	93,80 %
Mukherjee (2025)	LGBM + SMOTE-ENN + Bayes	99,59 %
Este trabajo (SVM)	SVM, sin balanceo	92,54 %
Este trabajo (PCA)	SVM + PCA 7 comp	92,47 %

Nuestros resultados están alineados con Koklu y Ozkan (2020). La diferencia respecto a Mukherjee (2025) se explica por su pipeline más elaborado: optimización bayesiana exhaustiva, selección dirigida de features y combinación SMOTE-ENN ajustada. Aunque replicar dicha tubería excede el alcance del curso, queda como dirección clara de mejora.

REFERENCIAS

- [1] M. Koklu e I. A. Ozkan, "Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques," *Computers and Electronics in Agriculture*, vol. 174, art. 105507, 2020. DOI: 10.1016/j.compag.2020.105507.
- [2] M. S. Khan, T. D. Nath, M. M. Hossain *et al.*, "Comparison of multiclass classification techniques using dry bean dataset," *International Journal of Cognitive Computing in Engineering*, vol. 4, pp. 6–20, 2023. DOI: 10.1016/j.ijcce.2023.01.002.
- [3] S. Krishnan, "Identification of Dry Bean Varieties Based on Multiple Attributes Using CatBoost Machine Learning Algorithm," *Scientific Programming*, art. 2556066, 2023. DOI: 10.1155/2023/2556066.
- [4] C. Li *et al.*, "Clustering and classification for dry bean feature imbalanced data," *Scientific Reports*, vol. 14, art. 82253, 2024. DOI: 10.1038/s41598-024-82253-6.
- [5] A. Mukherjee, M. R. Chalak Qazani, B. M. J. Rana *et al.*, "SMOTE-ENN resampling technique with Bayesian optimization for multi-class classification of dry bean varieties," *Applied Soft Computing*, vol. 181, art. 113467, 2025. DOI: 10.1016/j.asoc.2025.113467.